Machine Learning

Chapter 2 지도 학습(Supervised Learning)

START

Smart Media
스마트미디어인재개발원

학습목표

- 일반화, 과대적합, 과소적합을 이해 할 수 있다.
- KNN 알고리즘을 이해 할 수 있다.
- 하이퍼파라미터 튜닝을 할 수 있다.

일반화,과대적합,과소적합

일반화, 과대적합, 과소적합

아이에게 공이 무엇인지 알려주자

일반화, 과대적합, 과소적합

공이라는 것은..

둥글게 생겼다.
오각형이 여러 개 붙어있다.
검은색과 흰색으로 구성된다.
반짝반짝 광이 난다.

일반화, 과대적합, 과소적합

공이라는 것은..

과대적합

둥글게 생겼다.

[illegible] 붙어있다.

[illegible]로 구성된다.

반짝반짝 광이 난다.

일반화, 과대적합, 과소적합

공이라는 것은..

둥글게 생겼다.

일반화, 과대적합, 과소적합

공이라는 것은..

과소적합

일반화, 과대적합, 과소적합

일반화 (Generalization)

- 훈련 세트로 학습한 모델이 테스트 세트에 대해 정확히 예측하도록 하는 것 .

과대적합 (Overfitting)

- 훈련 세트에 너무 맞추어져 있어 테스트 세트의 성능 저하.

과소적합 (Underfitting)

- 훈련 세트를 충분히 반영하지 못해 훈련 세트, 테스트 세트에서 모두 성능이 저하.

일반화, 과대적합, 과소적합

일반화 성능이 최대화 되는 모델을 찾는 것이 목표

과대적합 (Overfitting)

- 너무 상세하고 복잡한 모델링을 하여 훈련데이터에만 과도하게 정확히 동작하는 모델.

과소적합 (Underfitting)

- 모델링을 너무 간단하게 하여 성능이 제대로 나오지 않는 모델.

일반화, 과대적합, 과소적합

모델 복잡도 곡선

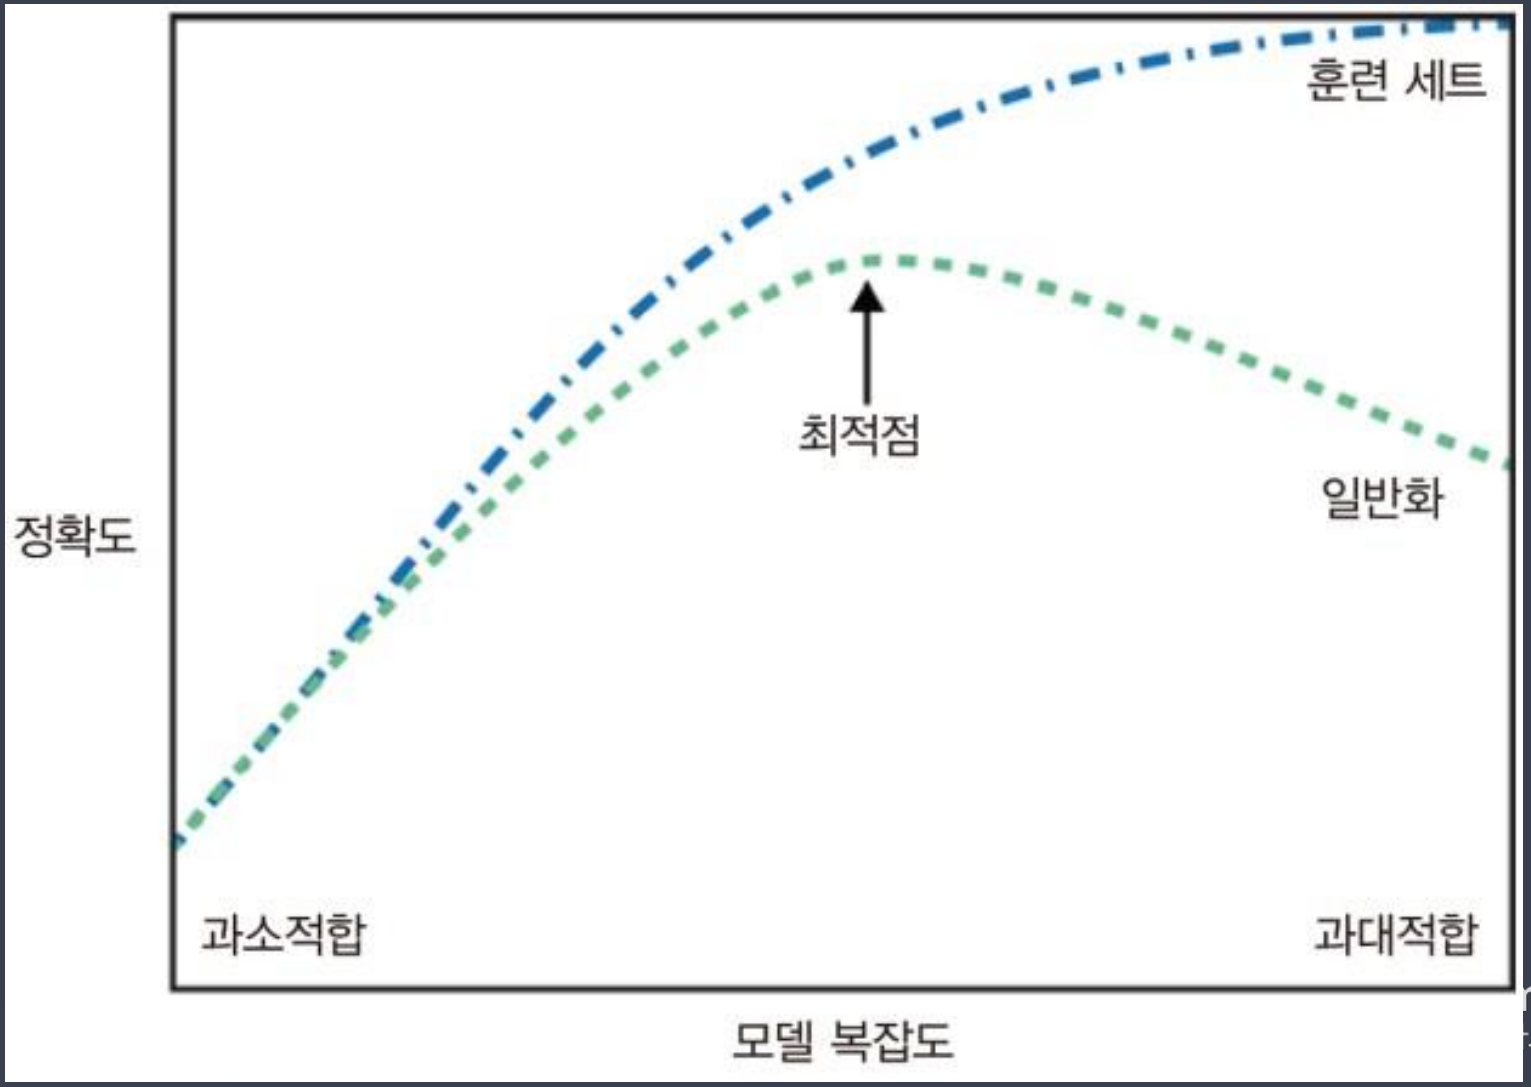

일반화, 과대적합, 과소적합

해결방법

- 주어진 훈련데이터의 다양성이 보장되어야 한다. 다양한 데이터 포인트를 골고루 나타내야 한다.
- 일반적으로 데이터 양이 많으면 일반화에 도움이 된다.
- 하지만 편중된 데이터를 많이 모으는 것은 도움이 되지 않는다.
- 규제(Regularization)을 통해 모델의 복잡도를 적정선으로 설정한다.

K-Nearest Neighbors (KNN)

K-Nearest Neighbors (KNN)

k-최근접 이웃 알고리즘

- 새로운 데이터 포인트와 가장 가까운 훈련 데이터셋의 데이터 포인트를 찾아 예측
- k 값에 따라 가까운 이웃의 수가 결정
- 분류와 회귀에 모두 사용 가능

K-Nearest Neighbors (KNN)

k-최근접 이웃 알고리즘

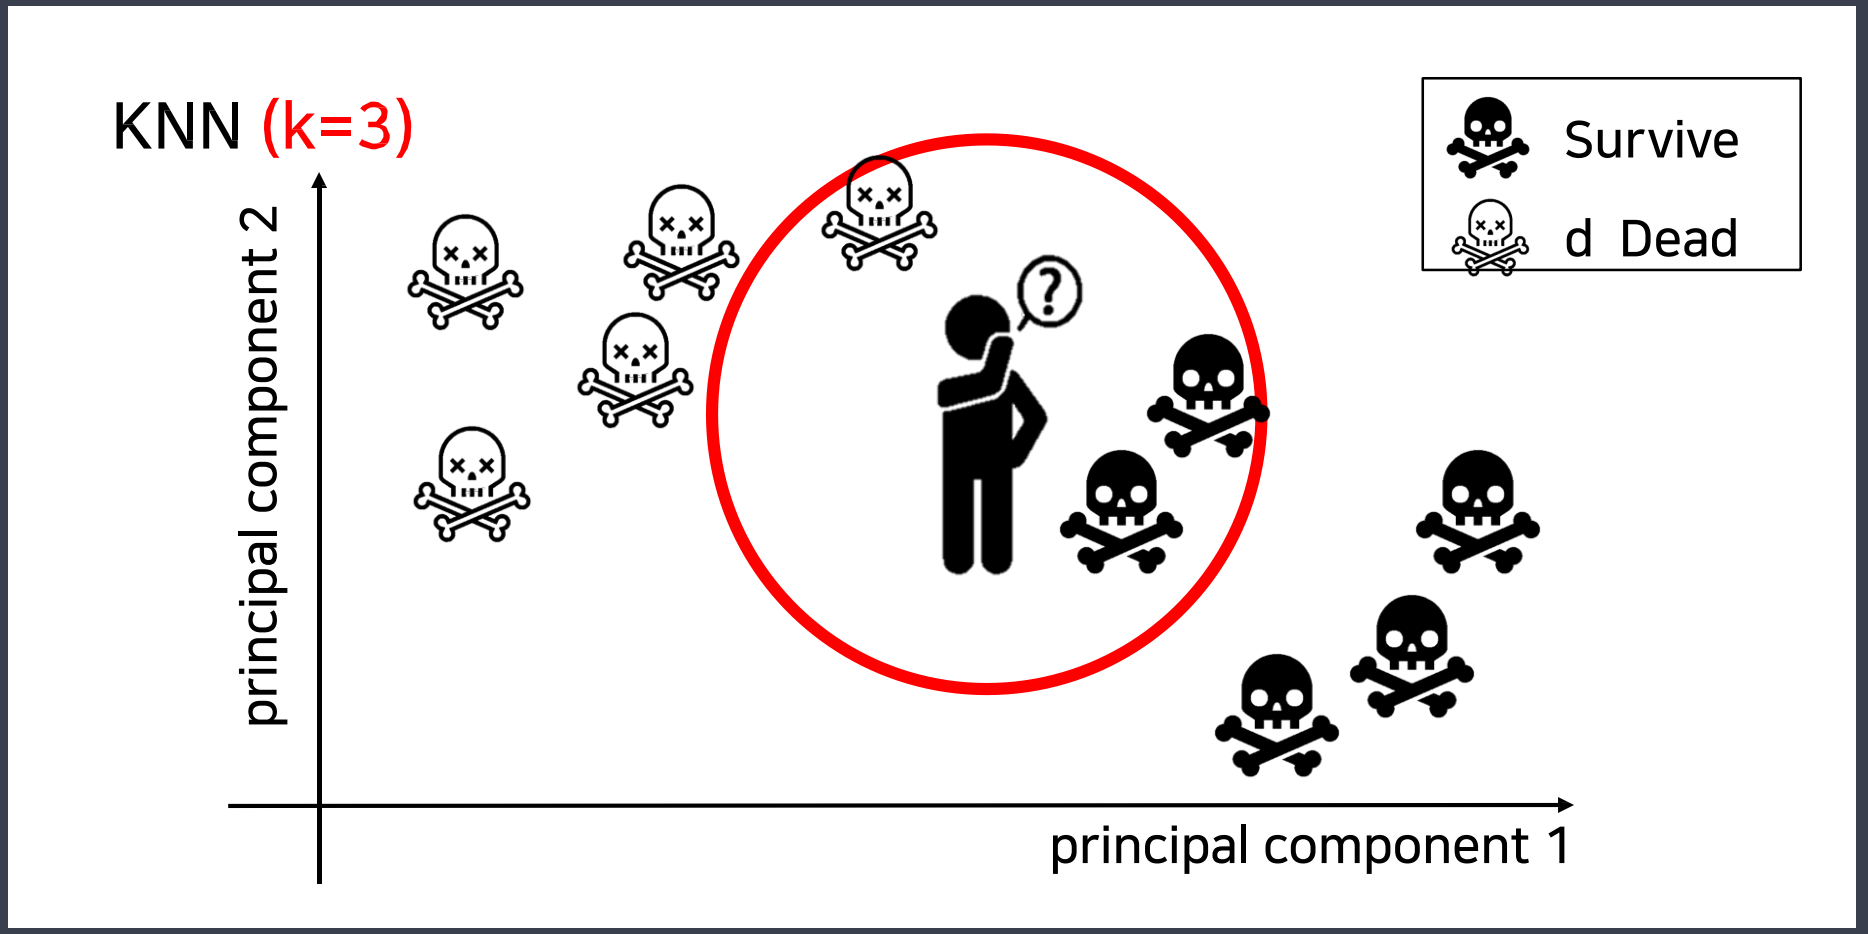

K-Nearest Neighbors (KNN)

k-최근접 이웃 알고리즘

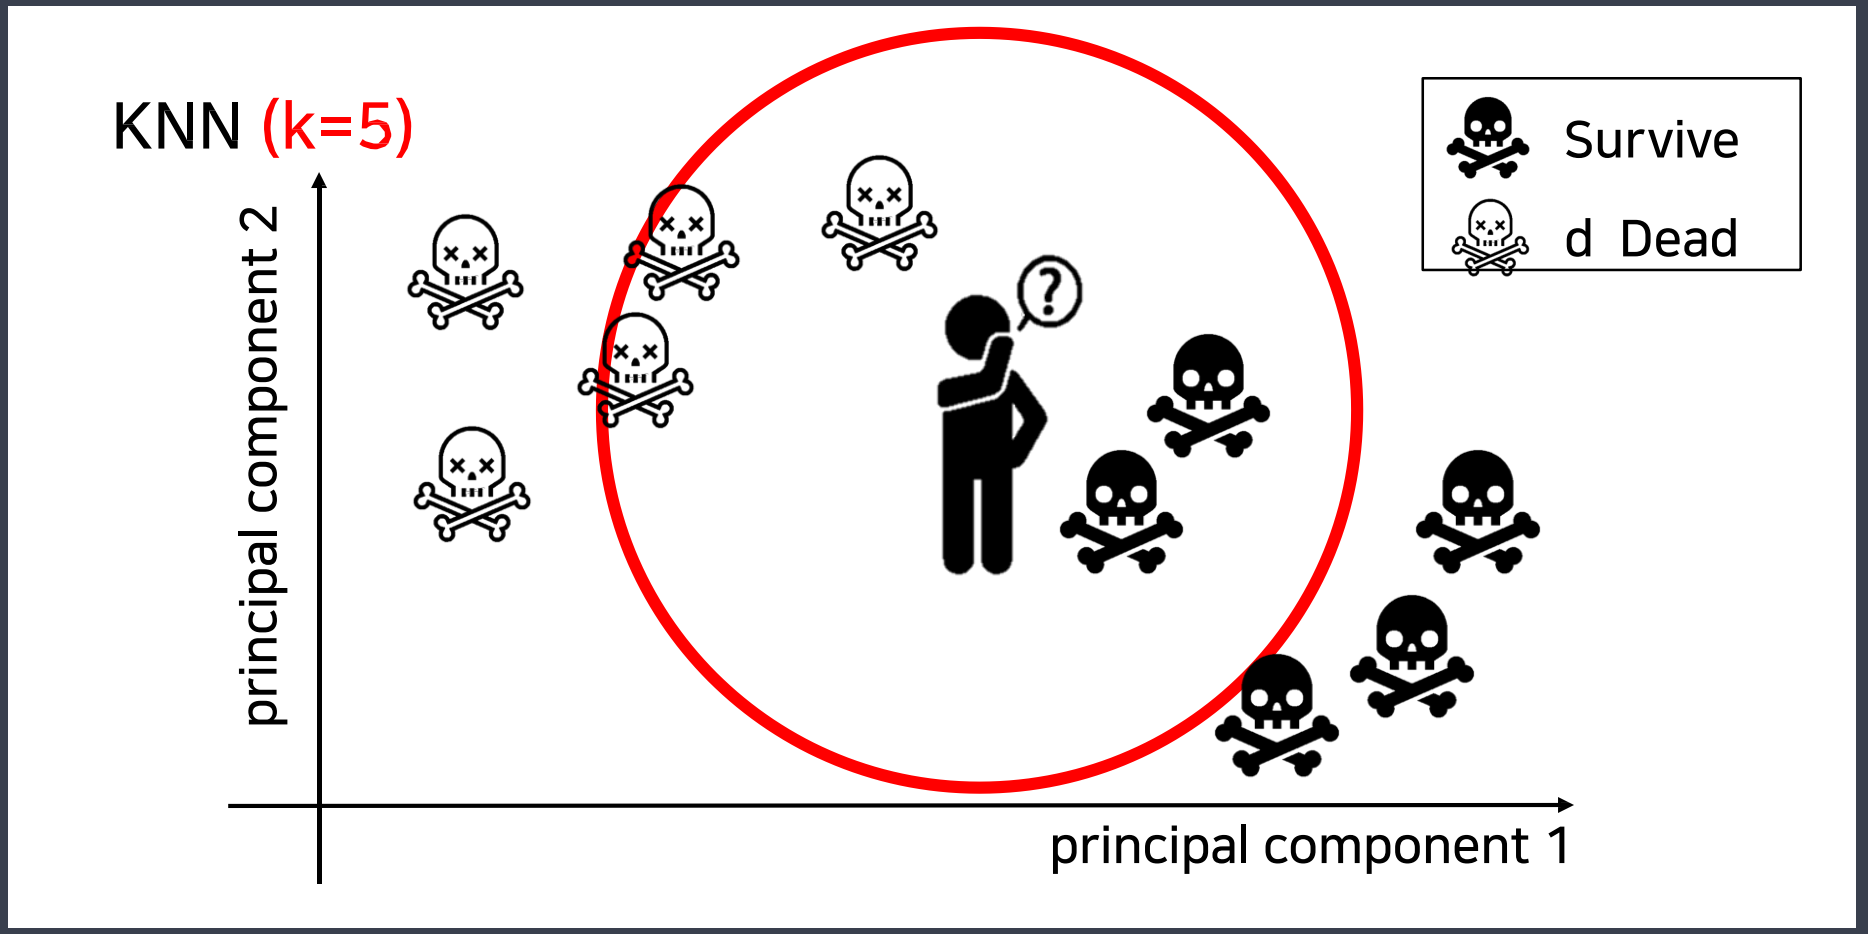

K-Nearest Neighbors (KNN)

k-최근접 이웃 알고리즘

- k 값이 작을 수록 모델의 복잡도가 상대적으로 증가.
- 반대로 k 값이 커질수록 모델의 복잡도가 낮아진다.
- 100개의 데이터를 학습하고 k를 100개로 설정하여 예측하면 빈도가 가장 많은 클래스 레이블로 분류

K-Nearest Neighbors (KNN)

장단점 및 주요 매개변수(Hyperparameter)

scikit-learn의 경우

```
KNeighborsRegressor(n_neighbors=이웃의 수)
```

K-Nearest Neighbors (KNN)

장단점 및 주요 매개변수(Hyperparameter)

- 이해하기 매우 쉬운 모델
- 훈련 데이터 세트가 크면(특성,샘플의 수) 예측이 느려진다
- 수백 개 이상의 많은 특성을 가진 데이터 세트와 특성 값 대부분이 0인 희소(sparse)한 데이터 세트에는 잘 동작하지 않는다
- 거리를 측정하기 때문에 같은 scale을 같도록 정규화 필요

K-Nearest Neighbors (KNN) 실습 - ex03

iris 데이터를 이용한 KNN 분류 실습

K-Nearest Neighbors (KNN) 실습 - ex03

붓꽃(iris) 데이터셋

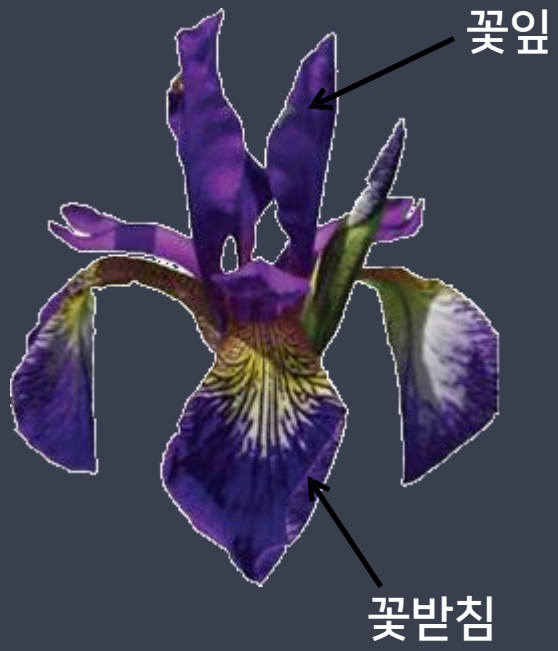

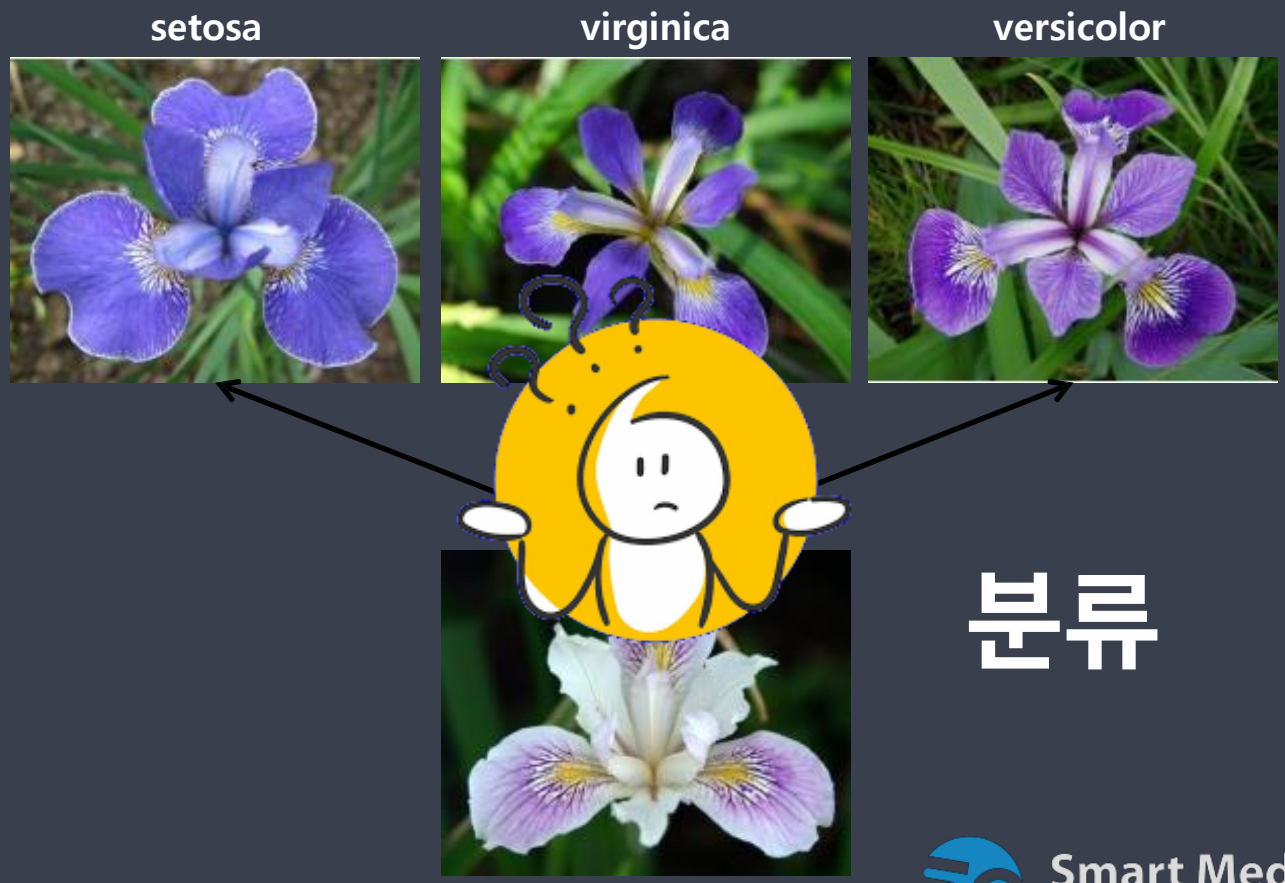

분류

K-Nearest Neighbors (KNN) 실습 - ex03

붓꽃(iris) 데이터셋

- 150개의 데이터
- 4개의 특성과 1개의 클래스(3개의 품종)로 구성

	sepal_length	sepal_width	petal_length	petal_width	species
	꽃받침 길이	꽃받침 넓이	꽃잎 길이	꽃잎 넓이	품종
1	5.1	3.5	1.4	0.2	Iris-setosa
2	4.9	3.0	1.4	0.2	
3	4.7	3.2	1.3	0.2	
...					
150	5.9	3.0	5.1	1.8	Iris-virginica

K-Nearest Neighbors (KNN) 실습 - ex03

train_test_split() 함수

- 데이터 셋에서 훈련데이터와 테스트데이터로 분리하는 기능

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(X, y,
                                                    test_size = 0.3,
                                                    random_state=0)
```

X : 특성 데이터
y : 라벨 데이터
test_size : 테스트 셋의 비율 rando
m_state : 선택할 데이터 시드 weig
ht : 가중치 함수